

文件编号: ITSS-10-02-02

版 本: V1.0

青岛瑞源工程集团有限公司

烟台林海嵎峡田综合体智慧农业大数据 平台建设项目数据清洗策略实施方案

编制人: 张秀才

编制时间: 2025.01.10

审核人: 宋振

编制时间: 2025.01.10

批准人: 于瑞建

审批时间: 2025.01.10

修订记录

日期	版本	变更说明	编写人	审核人	批准人
2025. 1. 10	V1. 0	新建文档	张秀才	宋 振	于瑞建

目录

青岛瑞源工程集团有限公司 1

烟台林海嵎峡田综合体智慧农业大数据平台建设项目数据清洗策略实施方案 ... 1

1. 总则 4

 1.1. 方案目的 4

 1.2. 编制依据 4

 1.3. 总体目标 4

2. 数据清洗详细设计 4

 2.1. 分域清洗策略 4

 2.1.1. 视频与图像数据域 4

 2.1.2. 物联网感知数据域 5

 2.1.3. 基础设施日志数据域 5

 2.1.4. 业务与应用数据域 5

 2.2. 技术架构与实施路径 5

3. 实施与管理规划 6

 3.1. 阶段化实施计划 6

 3.2. 组织与职责分工 6

 3.3. 关键交付物 6

4. 验收标准 7

5. 保障措施 7

6. 附则 7

1. 总则

1.1. 方案目的

为保障“烟台林海嵎峡田综合体智慧农业大数据平台”的决策准确性与系统可靠性，特制定本数据清洗策略方案。本方案旨在系统性地规划与设计数据清洗工作，确保源自各类物联网设备、视频监控及业务系统的多源异构数据，在汇入核心平台前具备可信、一致、及时的质量特征，从而支撑上层智慧应用实现预期价值。

1.2. 编制依据

本方案严格遵循《烟台林海嵎峡田综合体智慧农业大数据平台建设项目数据清洗策略需求分析报告》中提出的核心业务目标、质量要求与管理流程需求，是指导项目数据清洗工作实施的纲领性文件。

1.3. 总体目标

本方案致力于达成三大目标：一是达成预设的数据质量关键绩效指标，满足精准农业与智能安防的业务需求；二是建立一套权责清晰、流程可控、持续改进的数据质量管理闭环；三是交付高质量的数据资产及配套的治理能力，确保项目长效运营。

2. 数据清洗详细设计

2.1. 分域清洗策略

针对项目四大数据域的特征，实施差异化清洗。

2.1.1. 视频与图像数据域

本域数据主要来源于高清摄像机、AI布控球机等设备，核心问题在于视频流稳定性、时间同步及智能分析结果的可信度。

清洗策略包括：实施视频流健康度心跳监测，对短暂中断进行技术补偿，长

期中断则即时告警；强制统一所有视频源采用平台中心时钟，消除时间戳错乱；对AI模型产出的结构化数据（如车牌、人脸）设定置信度阈值，低置信度结果自动转入人工复核流程，确保输出结果的高可靠性。

2.1.2. 物联网感知数据域

本域数据源于太阳能系统、环境传感器等，表现为连续的时序数据，易受干扰产生噪声、跳变或通信中断。

清洗策略包括：依据设备物理参数与农业业务常识，为各类传感器数据设定合理的数值范围阈值，自动过滤超量程的无效数据；采用滑动平均等算法对时序数据进行平滑处理，抑制随机噪声；针对数据传输中的缺失，制定分级策略，对短时缺失进行线性插值，对长时缺失明确标记并触发设备运维工单。

2.1.3. 基础设施日志数据域

本域数据来自网络设备、服务器、存储阵列等，格式多样，信息粒度细，关键事件易被淹没。

清洗策略包括：制定统一的日志解析规范，从各行日志中准确提取时间、设备标识、事件级别与关键消息等标准字段；建立规则引擎，从海量日志中实时过滤并归类错误、警告及表征性能瓶颈的关键事件，为系统健康监控提供精准输入。

2.1.4. 业务与应用数据域

本域数据包括平台内外部业务系统产生的数据，主要存在标准不统一、记录重复及逻辑矛盾等问题。

清洗策略包括：开展主数据治理，对设备、地块、组织机构等核心实体定义全局唯一编码与规范属性，并在各系统间同步；在数据入库的ETL过程中，执行严格的格式转换、代码值映射、基于规则的记录去重与矛盾校验，确保数据内在一致性。

2.2. 技术架构与实施路径

采用“边缘轻量校验+平台集中治理”的混合架构。在靠近数据源的边缘侧部

署轻量逻辑，进行基础完备性校验与格式规整；在平台数据中心部署Flink实时计算引擎与Spark批量处理框架，分别负责流式数据的实时清洗与历史数据的批量治理。通过Apache Airflow进行任务调度，利用Prometheus配合Grafana监控数据流水线性能与质量指标。清洗规则力求实现配置化管理，通过规则引擎或配置文件驱动，提升可维护性。

3. 实施与管理规划

3.1. 阶段化实施计划

数据清洗工作将完全融入项目90天的总建设周期，分四阶段推进。

第一阶段（第1-30天）：规则设计与开发。完成各数据域清洗规则的详细设计、评审与核心代码开发。

第二阶段（第31-60天）：集成联调与试运行。清洗模块与硬件设备、业务系统对接联调，利用模拟或历史数据进行全流程试运行并优化。

第三阶段（第61-75天）：全量上线与监控。随系统正式上线启动全量数据清洗，并开启全天候质量监控。

第四阶段（第76-90天）：验收与交付。进行稳定性考核，输出最终质量报告，完成专项验收。

3.2. 组织与职责分工

甲方项目组业务侧负责清洗规则所涉及业务逻辑的最终评审与确认，并参与验收测试。甲方项目组技术侧负责本方案及技术交付物的评审，监督实施质量与进度。乙方作为实施方，须严格依据本方案完成设计、开发、部署、测试及运维全流程工作，并定期提交进展报告。

3.3. 关键交付物

实施方需按阶段提交以下交付物：《详细数据清洗规则设计说明书》、《数据清洗模块测试报告》、《数据质量监控平台操作手册》、《周期性数据质量分析报告》以及项目竣工时提交的《数据清洗专项竣工报告》，其中必须包含关键

绩效指标达成情况的证明。

4. 验收标准

数据清洗工作的验收以可量化、可验证的关键绩效指标为核心标准。在项目最终验收前，需提供连续15天的稳定运行数据，证明以下核心指标已持续达标：

视频图像域方面，AI识别准确率不低于95%；物联网感知域方面，关键传感器数据采集率不低于99%；业务应用域方面，核心业务数据交付准时率不低于99.5%；在过程质量方面，数据清洗任务执行成功率不低于99.9%；在系统性能方面，95%的数据记录其端到端清洗延迟不超过10秒。

5. 保障措施

为应对规则随业务变化而调整的风险，将建立严格的《数据清洗规则变更管理流程》，任何变更需经甲方业务负责人书面审批。为杜绝数据在清洗过程中失真且无法追溯，所有数据处理环节必须记录完整的数据血缘日志。为避免系统性能瓶颈，清洗平台需通过高于当前数据峰值50%的压力测试。为保证沟通顺畅，将建立双周数据质量例会制度，及时同步问题、评审报告并决策优化方向。

6. 附则

本方案经甲方项目指导委员会评审通过后生效，即成为本项目数据清洗工作的最高执行依据。方案所有附件与本方案正文具有同等效力。