

文件编号: ITSS-10-02-03

版 本: V1.0

青岛瑞源工程集团有限公司

烟台林海嵎峡田综合体智慧农业大数据 平台建设项目数据清洗策略实施方法

编制人: 张秀才

编制时间: 2025.01.10

审核人: 宋振

编制时间: 2025.01.10

批准人: 于瑞建

审批时间: 2025.01.10

修订记录

日期	版本	变更说明	编写人	审核人	批准人
2025. 1. 10	V1. 0	新建文档	张秀才	宋 振	于瑞建

目录

青岛瑞源工程集团有限公司 1

烟台林海嵎峡田综合体智慧农业大数据平台建设项目数据清洗策略实施方法 ... 1

1. 文档概述 4

 1.1. 目的 4

 1.2. 适用范围 4

 1.3. 术语定义 4

2. 实施目标 5

 2.1. 数据质量目标 5

 2.2. 业务支撑目标 5

3. 具体实施策略 5

 3.1. 分域清洗实施要点 5

 3.2. 技术工具与操作流程 6

4. 详细实施步骤 6

 4.1. 第一阶段：规则设计与环境准备（第1-30天） 6

 4.2. 第二阶段：集成联调与试运行（第31-60天） 7

 4.3. 第三阶段：全量上线与监控（第61-75天） 7

 4.4. 第四阶段：验收支持与知识转移（第76-90天） 7

5. 风险管理与质量控制 7

 5.1. 关键风险与应对 7

 5.2. 质量控制活动 8

6. 交付物清单 8

1. 文档概述

1.1. 目的

本文档旨在为"烟台林海嵎峡田综合体智慧农业大数据平台建设项目"提供具体、可操作的数据清洗实施方法。本方法严格遵循《数据清洗策略需求分析报告》的业务需求与《数据清洗策略方案》的技术架构，确保数据清洗工作能够高质量、高效率地落地执行，保障平台数据的准确性、一致性与时效性。

1.2. 适用范围

本方法适用于本项目所有数据源的清洗实施工作，具体包括但不限于以下四类数据域：

视频与图像数据域：各类高清摄像机、AI布控系统产生的视频流、图片及结构化数据。

物联网感知数据域：太阳能系统、环境传感器等产生的时序数据。

基础设施日志数据域：网络设备、服务器、存储阵列等产生的日志与状态数据。

业务与应用数据域：平台各业务系统产生的管理数据、配置数据与事务数据。

本方法主要面向数据工程师、开发人员及运维实施团队，为其提供具体的技术操作指引。

1.3. 术语定义

数据清洗：指按照预定义的业务规则与技术逻辑，对原始数据进行检测、修正、转换或标记，以提升其准确性、完整性、一致性、唯一性与时效性的过程。

数据质量KPI：衡量数据清洗效果的关键量化指标，如准确率、采集率、延迟等。

数据血缘：记录数据从源头到最终形态的完整处理路径与变换关系。

2. 实施目标

2.1. 数据质量目标

通过实施本方法，确保清洗后数据达到以下量化标准：

准确性：核心业务字段值与其真实状态的一致性，AI识别准确率不低于95%。

完整性：关键数据采集无缺失，物联网感知数据有效采集率不低于99%。

一致性：同一实体在不同系统中的标识与属性完全统一，主数据一致率达到100%。

时效性：数据从产生到可用的端到端延迟（P95）不超过10秒。

唯一性：业务数据中的重复记录率低于0.1%。

2.2. 业务支撑目标

为智慧农业决策提供可信赖的环境与生产数据。

为园区安防提供实时、准确的视频与事件数据。

为运营大屏与综合管理提供一致、及时的数据指标。

3. 具体实施策略

3.1. 分域清洗实施要点

视频与图像数据域：部署视频流健康度监测服务，实时检测断流并尝试补帧；采用网络时间协议（NTP）强制统一所有视频设备时钟；在AI分析服务器侧，对识别结果（如车牌、人脸）增加置信度过滤层，低于阈值（如0.9）的结果自动转存至待人工复核库，同时记录日志供模型优化。

物联网感知数据域：在数据接入层部署规则引擎，对每一条传感数据执行阈值校验（如土壤湿度范围0-100%），超出范围则标记为"异常"并触发告警；对时序数据流采用滑动窗口进行平滑滤波；建立设备心跳机制，对持续无信号设备生成运维工单，其缺失数据在业务侧标记为"设备离线"。

基础设施日志数据域：通过日志采集代理（如Filebeat）统一收集日志，并使用预定义的解析规则（正则表达式或GROK模式）提取关键字段；搭建

Elasticsearch集群存储日志，并设置告警规则，对"ERROR"、"CRITICAL"级别日志及关键性能指标（如CPU>90%）进行实时通知。

业务与应用数据域：在数据仓库ODS层实施ETL清洗，包括格式标准化（日期、数值）、代码统一映射（如天气代码转换）、基于关键字段（如设备ID、时间戳）的去重处理；建立主数据管理模块，维护设备、地块等核心实体的唯一编码，并在各系统间通过服务接口同步。

3.2. 技术工具与操作流程

实时清洗：采用Apache Flink作为流处理引擎，消费Kafka中的实时数据，执行上述分域清洗逻辑，并将结果写回Kafka或直接入库。

批量清洗：使用Apache Spark编写清洗作业，处理历史数据或T+1的增量数据，调度依赖Airflow管理。

规则管理：清洗规则以JSON配置文件形式存储，并通过内部管理界面进行发布、更新与回滚，实现规则与代码解耦。

监控验证：利用Prometheus收集清洗作业的吞吐量、延迟、错误率等指标，并通过Grafana配置数据质量KPI看板。

4. 详细实施步骤

4.1. 第一阶段：规则设计与环境准备（第1-30天）

数据源对接：与各设备厂商确认数据接口协议（如GB/T28181、ONVIF、MQTT），完成接入调试。

规则细化开发：依据《数据清洗策略方案》中的规则设计要点，编写具体的Flink/Spark清洗代码与配置文件。

测试环境部署：搭建与生产环境一致的测试集群，部署清洗程序与相关依赖组件。

交付物：《详细数据清洗规则说明书》、《测试环境部署报告》。

4.2. 第二阶段：集成联调与试运行（第31-60天）

模块集成：将清洗模块与视频管理平台、物联网平台、数据中台等进行联调，确保数据通路畅通。

试运行与调优：使用真实历史数据或模拟数据开展至少15天的试运行，监控清洗效果，并根据业务反馈调整规则参数。

交付物：《数据清洗模块集成测试报告》、《试运行数据质量分析报告》。

4.3. 第三阶段：全量上线与监控（第61-75天）

生产环境部署：将经测试验证的清洗程序与配置部署至生产环境。

监控体系启用：全面开启数据质量监控看板与告警，实施7x24小时运行监控。

交付物：《生产环境部署手册》、《数据质量监控看板使用指南》。

4.4. 第四阶段：验收支持与知识转移（第76-90天）

稳定性运行：保障清洗系统连续稳定运行，收集验收所需的KPI数据。

文档与培训：整理全部实施文档，并向甲方运维团队提供一次系统性的操作培训。

交付物：《数据清洗系统运维手册》、《培训记录》、《最终数据清洗竣工报告》（含KPI达标证明）。

5. 风险管理与质量控制

5.1. 关键风险与应对

规则逻辑错误风险：所有清洗规则在上线前必须通过业务逻辑评审与数据样本测试，并在测试环境充分验证。变更需走审批流程。

数据丢失与失真风险：清洗前对原始数据永久备份（如对象存储），清洗过程中记录完整数据血缘日志，确保任何数据都可追溯还原。

系统性能瓶颈风险：清洗系统需通过至少1.5倍业务峰值压力的性能测试，并设置弹性伸缩策略。

沟通与协作风险：与甲方建立双周例会制度，同步进展、评审报告，并使用协同平台管理数据质量问题工单。

5.2. 质量控制活动

代码审查：所有清洗脚本与配置变更需经过同级评审。

测试用例：为每类清洗规则编写对应的单元测试与集成测试用例。

质量门禁：在CI/CD流水线中设置质量门禁，测试覆盖率、规则验证通过率不达标则禁止发布。

6. 交付物清单

本实施方法要求产出以下具体交付物，作为工作完成的证据与后续运维的依据：

《详细数据清洗规则说明书》

《数据清洗模块源代码及配置库》

《测试报告》（单元测试、集成测试、性能测试）

《生产环境部署与配置文档》

《数据质量监控看板与告警规则说明》

《数据清洗系统运维手册》

《最终数据清洗竣工报告》（必须附有连续15天KPI达标的数据截图与说明）

附件：

数据清洗规则配置文件示例（JSON格式）

数据血缘日志记录格式说明

数据质量告警工单模板